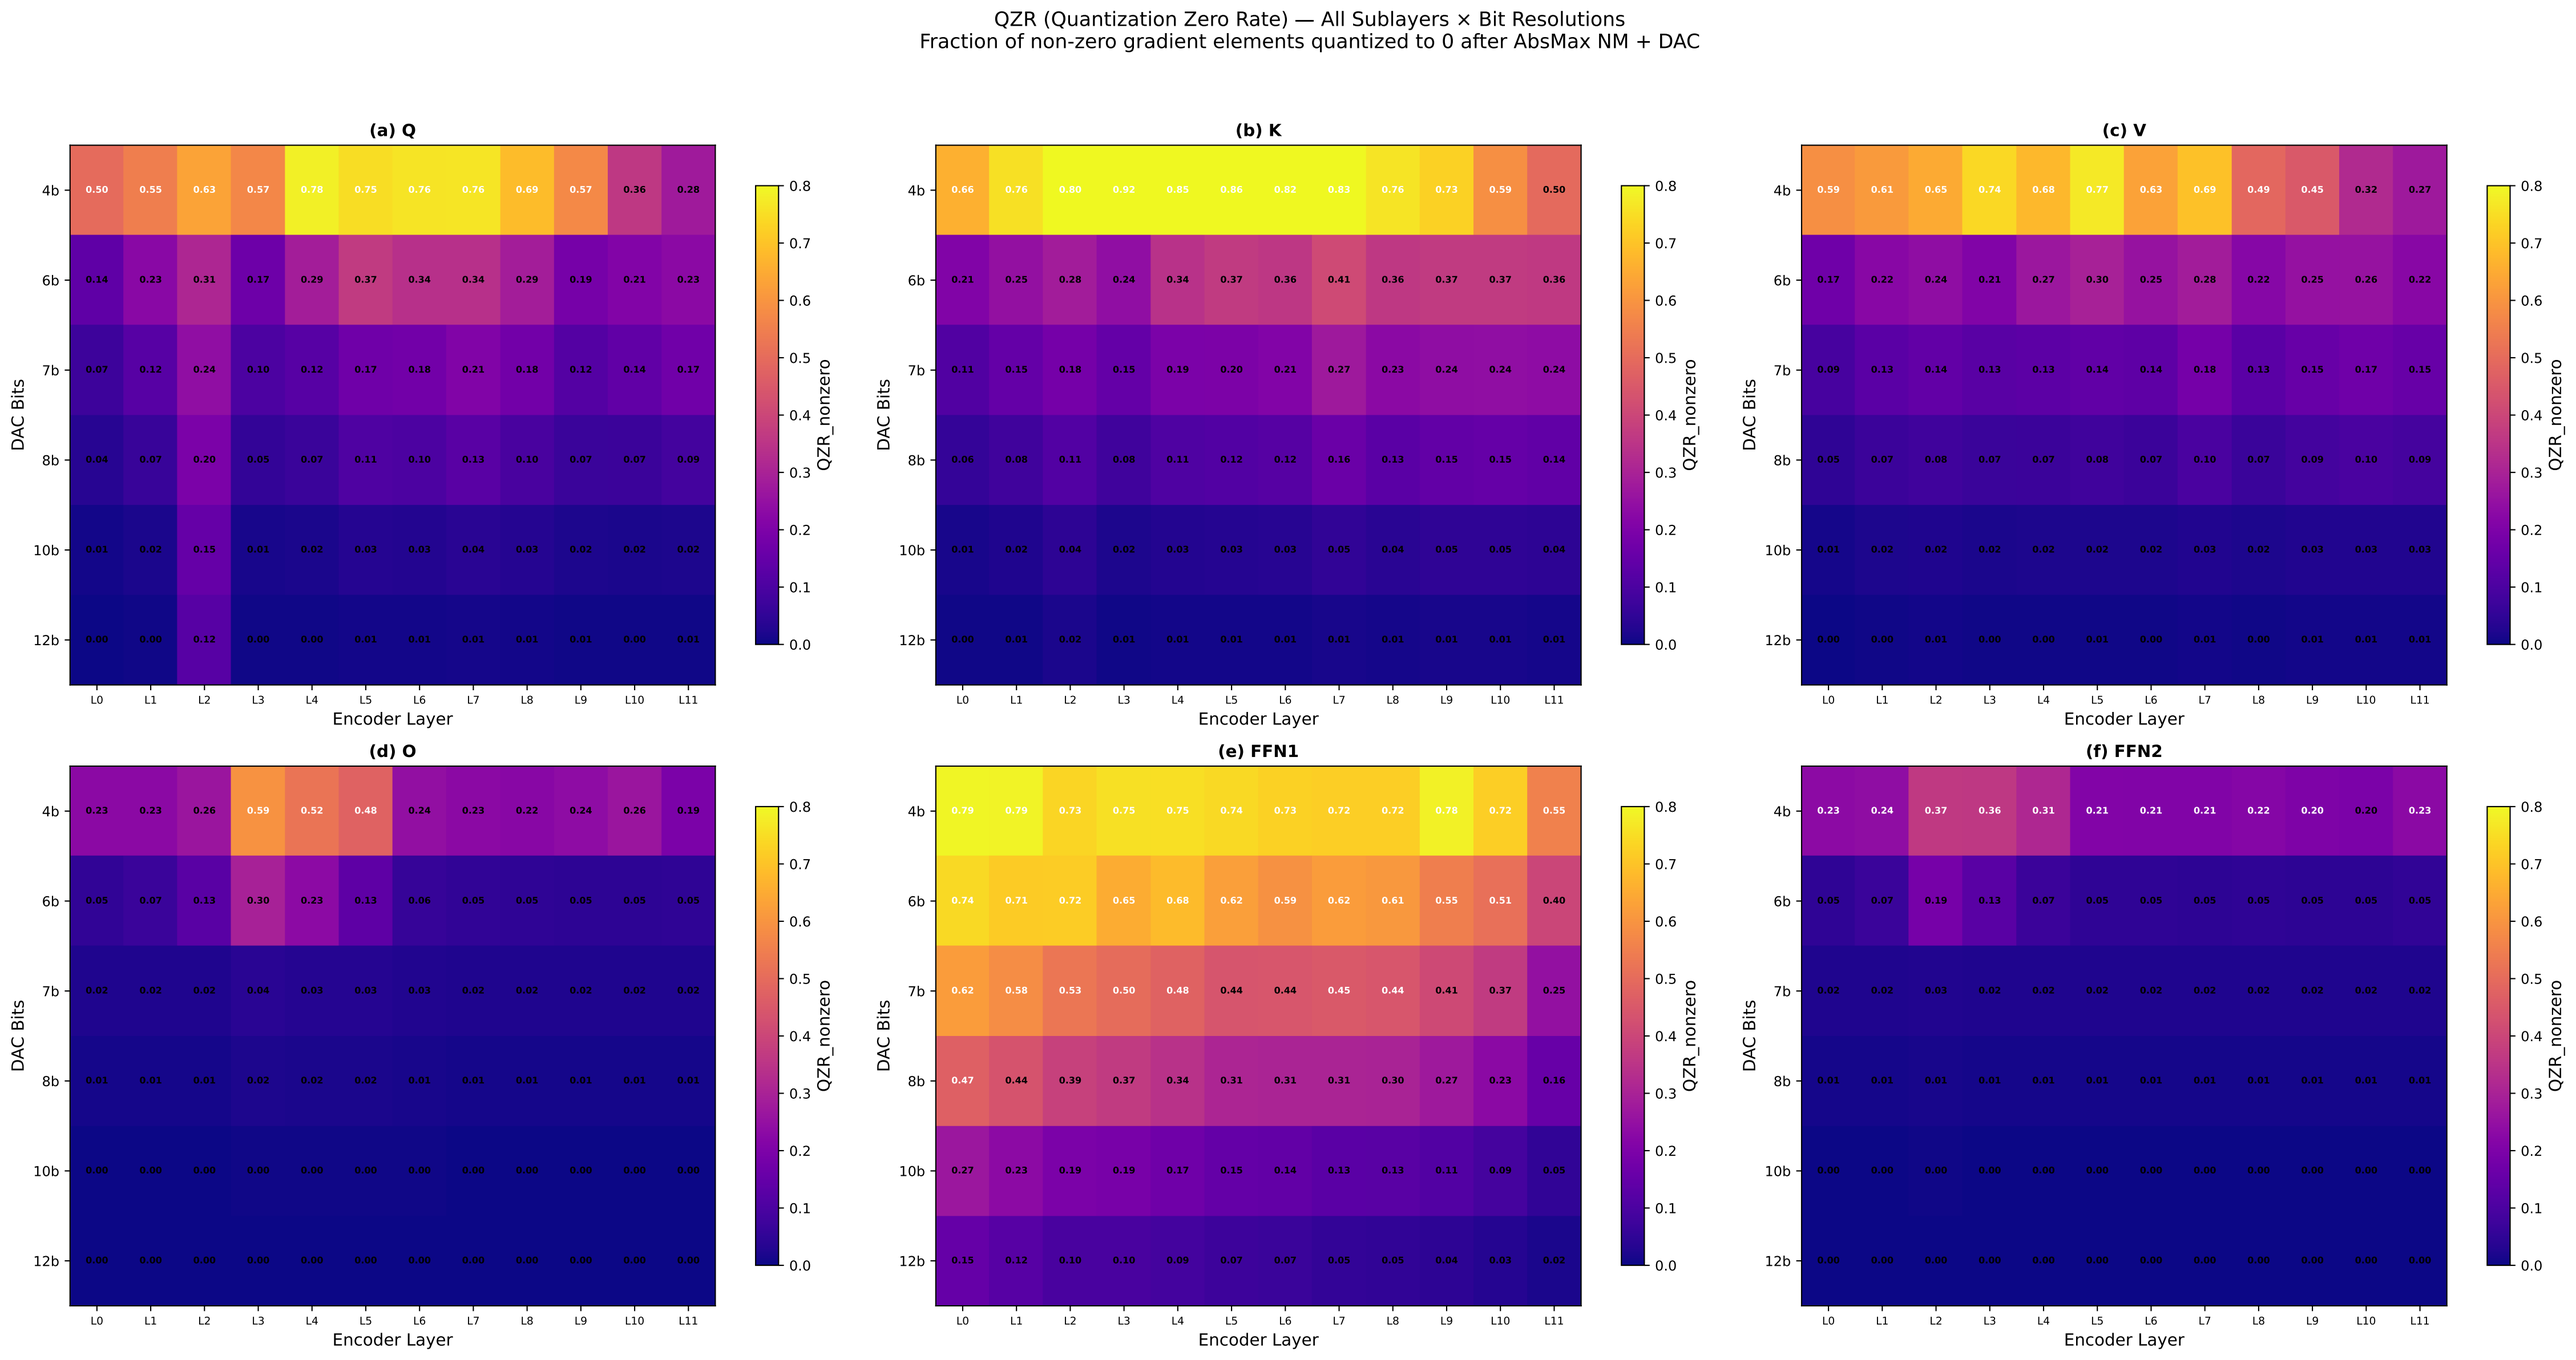

QZR (Quantization Zero Rate) — All Sublayers × Bit Resolutions
Fraction of non-zero gradient elements quantized to 0 after AbsMax NM + DAC
(a) Q
4b 0.50 0.55 0.63 0.57 0.78 0.75 0.76 0.76 0.69 0.57 0.36 0.28
6b 0.14 0.23 0.31 0.17 0.29 0.37 0.34 0.34 0.29 0.19 0.21 0.23
7b 0.07 0.12 0.24 0.10 0.12 0.17 0.18 0.21 0.18 0.12 0.14 0.17
8b 0.04 0.07 0.20 0.05 0.07 0.11 0.10 0.13 0.10 0.07 0.07 0.09
10b 0.01 0.02 0.15 0.01 0.02 0.03 0.03 0.04 0.03 0.02 0.02 0.02
12b 0.00 0.00 0.12 0.00 0.00 0.01 0.01 0.01 0.01 0.01 0.00 0.01
(b) K
4b 0.66 0.76 0.80 0.92 0.85 0.86 0.82 0.83 0.76 0.73 0.59 0.50
6b 0.21 0.25 0.28 0.24 0.34 0.37 0.36 0.41 0.36 0.37 0.37 0.36
7b 0.11 0.15 0.18 0.15 0.19 0.20 0.21 0.27 0.23 0.24 0.24 0.24
8b 0.06 0.08 0.11 0.08 0.11 0.12 0.12 0.16 0.13 0.15 0.15 0.14
10b 0.01 0.02 0.04 0.02 0.03 0.03 0.03 0.05 0.04 0.05 0.05 0.04
12b 0.00 0.01 0.02 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01
(c) V
4b 0.59 0.61 0.65 0.74 0.68 0.77 0.63 0.69 0.49 0.45 0.32 0.27
6b 0.17 0.22 0.24 0.21 0.27 0.30 0.25 0.28 0.22 0.25 0.26 0.22
7b 0.09 0.13 0.14 0.13 0.13 0.14 0.14 0.18 0.13 0.15 0.17 0.15
8b 0.05 0.07 0.08 0.07 0.07 0.08 0.07 0.10 0.07 0.09 0.10 0.09
10b 0.01 0.02 0.02 0.02 0.02 0.02 0.02 0.03 0.02 0.03 0.03 0.03
12b 0.00 0.00 0.01 0.00 0.00 0.01 0.00 0.01 0.00 0.01 0.01 0.01
(d) O
4b 0.23 0.23 0.26 0.59 0.52 0.48 0.24 0.23 0.22 0.24 0.26 0.19
6b 0.05 0.07 0.13 0.30 0.23 0.13 0.06 0.05 0.05 0.05 0.05 0.05
7b 0.02 0.02 0.02 0.04 0.03 0.03 0.03 0.02 0.02 0.02 0.02 0.02
8b 0.01 0.01 0.01 0.02 0.02 0.02 0.01 0.01 0.01 0.01 0.01 0.01
10b 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00
12b 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00
(e) FFN1
4b 0.79 0.79 0.73 0.75 0.75 0.74 0.73 0.72 0.72 0.78 0.72 0.55
6b 0.74 0.71 0.72 0.65 0.68 0.62 0.59 0.62 0.61 0.55 0.51 0.40
7b 0.62 0.58 0.53 0.50 0.48 0.44 0.44 0.45 0.44 0.41 0.37 0.25
8b 0.47 0.44 0.39 0.37 0.34 0.31 0.31 0.31 0.30 0.27 0.23 0.16
10b 0.27 0.23 0.19 0.19 0.17 0.15 0.14 0.13 0.13 0.11 0.09 0.05
12b 0.15 0.12 0.10 0.10 0.09 0.07 0.07 0.05 0.05 0.04 0.03 0.02
(f) FFN2
4b 0.23 0.24 0.37 0.36 0.31 0.21 0.21 0.21 0.22 0.20 0.20 0.23
6b 0.05 0.07 0.19 0.13 0.07 0.05 0.05 0.05 0.05 0.05 0.05 0.05
7b 0.02 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.02 0.02 0.02 0.02
8b 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01
10b 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00
12b 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00
DAC Bits
Encoder Layer
L0 L1 L2 L3 L4 L5 L6 L7 L8 L9 L10 L11
QZR_nonzero
0.0 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8